EsnafDoktor (MerchantDoctor) — Teknik Rapor

Açık Ağırlıklı Gemma 3 4B ve Hibrit RAG ile Satıcıya Sorulan Sorulara Saniyeler İçinde Kurala Dayalı Yanıt

Yarışma: Hacktoberfest Elazığ 2026 (FÜBEV / MLH / DEV)
Tarih: 18 Ekim 2026
Lisans: MIT (Tamamen Açık Kaynak)
Hedef Ödüller: Gemma ($200), Open Source ($200), TabPFN ($200)
Altyapı: Yerel çıkarım, 0.00 TL API
Test Durumu: 7/7 birim testi geçti

1. Yönetici Özeti ve Problem Tanımı

E-ticaret sitelerinde satıcıya sorulan sorular (kargo nerede, beden değişimi, çift çekim, iade süresi) çoğu zaman saatlerce cevapsız kalır. Trendyol, Hepsiburada ve Instagram üzerinden satış yapan küçük satıcı hem siparişi paketler hem de günde yüzlerce mesaja yetişmeye çalışır. Geç yanıt pazar yeri mağaza puanını düşürür; her iade talebinin koşulsuz kabulü ise kullanılmış veya etiketi sökülmüş ürünlerde doğrudan zarar yazar. Mesaj başına ücretli bulut yapay zekâ servisleri ise maliyeti mesaj sayısıyla büyütür. **EsnafDoktor**, satıcının kendi bilgisayarında çalışan açık ağırlıklı bir modelle rutin soruları saniyeler içinde, mağazanın kendi kuralına dayanarak yanıtlar; riskli vakaları ise gerekçesiyle satıcıya iletir.

2. Teknik Mimari ve Model Dağılımı

Modül	Kullanılan Teknoloji	Görevi ve Sisteme Katkısı	Süre (ısınmış)
NLU Motoru	Türkçe anahtar kelime sınıflandırıcı (ince ayarlı BERTurk yuvası hazır)	Mesajı 3 niyete (şikâyet, bilgi, teşekkür) ayırır. Kategori, daha isabetli olan kural eşleşmesinden alınır.	< 1 ms
Hibrit RAG	BM25 + multilingual-e5-small + RRF + Cross-Encoder ağırlığı	16 mağaza kuralından doğrusunu bulur; kural düzeyinde %95,2 isabet.	~440 ms (CPU)
Tabular Risk	TabPFN entegrasyonu; lisans onayına kadar kalibre lojistik formül	Tutar, teslimat, iade geçmişi, açılış videosu ve hasar bildiriminden iade suistimali riskini hesaplar.	< 1 ms
Akıl Yürütme & Aksiyon	Gemma 3 4B (Ollama, yerel GPU) + dayanak denetimi	Yalnızca bulunan kurala dayanarak müşteriye yanıt yazar; kuralda geçmeyen sayı içeren yanıt reddedilir.	~1,4 sn

3. Jüri Analizi: Neden Açık Kaynak Kapalı API'den (GPT-4o) Üstün?

Kriter	Kapalı API (OpenAI GPT-4o / Claude)	EsnafDoktor (Yerel Açık Kaynak)
Değişken Maliyet	Mesaj başına ücret; maliyet mesaj sayısıyla büyür.	**0.00 TL.** Cihaz üzerinde sınırsız ve ücretsiz çalışır.
İnternet Bağımlılığı	Bağlantı koptuğunda yanıt üretilemez.	**Yerel çıkarım.** Modeller indirildikten sonra Wi-Fi kapalıyken de yanıt verir.
Veri Gizliliği (KVKK)	Müşteri adı, adresi, telefon numarası ve sepet tutarı yabancı buluta uçar.	**Sıfır Sızıntı.** Tüm müşteri kayıtları yerel sabit diskte kalır.
Kilitlenme	Fiyat ve model sağlayıcının elinde.	**Model değiştirilebilir.** Satıcı masasından Gemma, Qwen, Llama seçilir.

4. Deneysel Değerlendirme & Dürüst Akademik Metrikler

Tüm sayılar **python scripts/evaluate_honest_metrics.py** ile bu repoda yeniden üretilir (docs/metrics.md). Sınıflandırma, eğitimde kullanılmamış **20 vakalık Held-Out Gold Set** üzerinde; kural getirme ise doğru cevabı tek bir politika olan 21 günlük dil müşteri mesajında ölçülmüştür.

Görev / Test Katmanı	Metrik	Elde Edilen Değer	Açıklama & Hata Analizi
Kategori (sistem)	Doğruluk / Macro F1	**%95,0 / %93,8**	Kategori eşleşen kuraldan alınır. Anahtar kelime NLU'su tek başına %60,0 / %54,0'da kalır.
Niyet (anahtar kelime NLU)	Macro F1	**%61,2**	İnce ayarlı BERTurk dosyaları repoda değil; en zayıf halka ve sıradaki iyileştirme.
Kural getirme (kural düzeyi)	Hit@1	**%95,2** (20/21)	Ablasyon: BM25 %81,0 · E5 %71,4 · RRF %81,0 · Cross-Encoder tek başına 17/21.
Kural getirme (kategori düzeyi)	Hit@1 / Hit@3	**%100 / %100**	Doğru kategoriden herhangi bir kural isabet sayılır; kural düzeyinden daha kolay bir ölçüt.
Yanıt dayanak denetimi	İlk denemede geçen	**8/8**	Gemma 3 4B, 8 örnek soru ve yorum. Kuralda olmayan sayı içeren yanıt reddedilir, şablona dönülür.
Uçtan uca yanıt	Ortalama süre	**~2 sn**	Analiz ~0,46 sn (CPU) + Gemma ~1,4 sn (GPU, 2,9 GB). İlk istekte model yüklemesi ~7 sn.

5. Sentetik Veri İyileştirmesi: Robotik Şablondan Gerçek Hayata

Önceki çalışmalardaki mekanik slot doldurma (örn: *'Merhaba canli destekte bugun kargom gelmedi'*) yapaydı. Geliştirdiğimiz yeni üretim motorunda **8 farklı tüketici personası** (Öfkeli, Aceleci Genç, Yaşlı/Acemi, Pazarlıkçı vb.) tanımlanmış ve **%38.8 oranında mobil klavye gürültüsü** (ş->s, ç->c, bitişik harf kayması, noktalama eksikliği) enjekte edilerek **3.000 satırlık yüksek gerçekçilikli korpus** üretilmiştir.

6. Side Hustle İş Modeli & Sahadaki Değer

Tek bir sahte deri mont iadesi esnafa **5.800 TL** doğrudan zarar yazmaktadır. Hasarlı kargolarda zabıt tutanağı tutturulmadığı için kargo firmasının ödemediği tazminat esnafın cebinden çıkmaktadır. EsnafDoktor rutin soruları saatler yerine yaklaşık 2 saniyede yanıtlayarak mağaza puanını korur; riskli iadeleri gerekçesiyle satıcıya ileterek tek bir haksız iadenin yazacağı zararı önler. Mesaj başına API ücreti olmadığı için maliyet mesaj sayısıyla artmaz. Önerilen fiyatlandırma: tek seferlik 1.500 TL kurulum veya aylık 250 TL bakım.
